

Predição de Aprovação de Pedidos de Cartão de Crédito

Utilizando Aprendizado de Máquina para classificar bons e maus pagadores

36.457

clientes na base final




1,69%

maus pagadores



Uma avaliação mais rigorosa da generalização.



Da origem dos dados à base de modelagem

Duas fontes, um objetivo: transformar histórico de crédito em variável-alvo.



438.557

registros cadastrais

application_record.csv

+



1,048.575

registros de crédito

credit_record.csv

→



36.457

clientes finais

CONSTRUÇÃO DO TARGET

- ✓ **438.510** aplicantes únicos
- ✓ **45.985** com histórico
- ✓ **36.457** base final

TARGET = 1

pelo menos um STATUS 2, 3, 4 ou 5

98,31%
bons pagadores

1,69%
maus pagadores



Desbalanceamento forte → Accuracy não pode ser analisada isoladamente.

O desafio escondido estava nos perfis repetidos

O risco metodológico: o mesmo perfil aparecer em conjuntos diferentes.



9.728

perfis distintos



33.320

clientes em perfis repetidos



269

perfis com TARGET conflitante



419 / 616

maus pagadores em perfis conflitantes



SOLUÇÃO

- ✓ Agrupar pelo perfil cadastral
- ✓ StratifiedGroupKFold
- ✓ **0%** de sobreposição entre conjuntos

Três algoritmos. Um teste mais rigoroso.

Treino, validação e teste separados
por perfil cadastral.



TREINO

25.743

427 maus • 1,66%



VALIDAÇÃO

5.347

98 maus • 1,83%



TESTE

5.367

91 maus • 1,70%

MODELOS AVALIADOS



KNN

K = 1

F1 2,08%



Regressão Logística

Classificação linear

Recall 35,16%



Random Forest

Ensemble

AUC 0,6109



Critério de seleção do modelo: maior F1 da classe de maus pagadores.

O que o teste realmente mostrou

As métricas são da classe minoritária de maus pagadores, com avaliação agrupada.



KNN

Acurácia	96,50%
Precisão	1,98%
Recall	2,20%
F1	2,08%
AUC-ROC	0,5016



Regressão Logística

Acurácia	62,31%
Precisão	1,60%
Recall	35,16%
F1	3,07%
AUC-ROC	0,5065



Random Forest

Acurácia	94,93%
Precisão	4,52%
Recall	9,89%
F1	6,21%
AUC-ROC	0,6109



LEITURA EXECUTIVA

- Random Forest apresentou o melhor F1 da classe de maus pagadores (6,21%) e a maior AUC (0,6109).
- Regressão Logística obteve o maior recall (35,16%), porém com baixa precisão (1,60%).
- KNN apresentou desempenho inferior para a classe de maus pagadores.

Quais variáveis mais contribuíram para o modelo?

Importâncias do Random Forest — contribuição para o modelo, não causalidade.



Idade • tempo de emprego • renda
são os três maiores componentes
de importância.



As importâncias indicam o quanto cada variável
contribui para o modelo de Random Forest,
não significando relação de causalidade.

O principal resultado foi tornar o teste confiável.

A contribuição metodológica é tão importante quanto a métrica final.

01



AVALIAÇÃO

0% de sobreposição entre conjuntos

- ✓ Agrupamento por perfil
- ✓ StratifiedGroupKFold
- ✓ Teste mais confiável

02



MODELO

Random Forest • F1 6,21%
critério definido

- ✓ Maior F1 para TARGET = 1
- ✓ Comparado com 3 algoritmos
- ✓ Métricas avaliadas na classe minoritária

03



LEITURA

Sinal preditivo
ainda limitado

- ✓ RF: AUC-ROC 0,6109
- ✓ Discriminação superior, mas ainda limitada
- ✓ Não usar como decisão única

Obrigado.



USO RECOMENDADO

Ferramenta de apoio à análise de crédito — não um critério único de decisão.