

Predição de Aprovação de Pedidos de Cartão de Crédito

Utilizando Aprendizado de Máquina para classificar bons e maus pagadores

36.457

clientes na base final



1,69%

maus pagadores



Uma avaliação mais rigorosa da generalização.



Da origem dos dados à base de modelagem

Duas fontes, um objetivo: transformar histórico de crédito em variável-alvo.



CONSTRUÇÃO DO TARGET

- ✓ 438.510 aplicantes únicos
- ✓ 45.985 com histórico
- ✓ 36.457 base final

TARGET = 1

pelo menos um STATUS 2, 3, 4 ou 5

98,31%
bons pagadores

1,69%
maus pagadores



Desbalanceamento forte → Accuracy não pode ser analisada isoladamente.

O desafio escondido estava nos perfis repetidos

O risco metodológico: o mesmo perfil aparecer em conjuntos diferentes.



9.728

perfis distintos



33.320

clientes em perfis repetidos



269

perfis com TARGET conflitante



419 / 616

maus pagadores em perfis conflitantes



SOLUÇÃO

- ✓ Agrupar pelo perfil cadastral
- ✓ StratifiedGroupKFold
- ✓ **0%** de sobreposição entre conjuntos

Três algoritmos. Um teste mais rigoroso.

Treino, validação e teste separados por perfil cadastral.



TREINO

25.816

439 maus • 1,70%



VALIDAÇÃO

5.231

93 maus • 1,78%



TESTE

5.410

84 maus • 1,55%

MODELOS AVALIADOS



KNN

K = 1

F1 2,94%



Regressão Logística

Classificação linear

Recall 28,57%



Random Forest

Ensemble

AUC 0,5153



Critério de seleção do KNN: maior F1 da classe de maus pagadores.

O que o teste realmente mostrou

As métricas são da classe minoritária de maus pagadores, com avaliação agrupada.

MODELO	ACURÁCIA	PRECISÃO	RECALL	F1	AUC-ROC
 KNN	96,34%	2,50%	3,57%	2,94%	0,5069
 Regressão Logística	62,79%	1,21%	28,57%	2,33%	0,5115
 Random Forest	96,04%	1,49%	2,38%	1,83%	0,5153



LEITURA EXECUTIVA

- AUCs próximas de 0,50 indicam capacidade discriminativa limitada na configuração avaliada.
- KNN foi selecionado exclusivamente pelo critério definido no projeto: maior F1 para TARGET = 1.

Quais variáveis mais contribuíram para o modelo?

Importâncias do Random Forest — contribuição para o modelo, não causalidade.



Idade • tempo de emprego • renda
são os três maiores componentes
de importância.



As importâncias indicam o quanto cada variável
contribui para o modelo de Random Forest,
não significando relação de causalidade.

O principal resultado foi tornar o teste confiável.

A contribuição metodológica é tão importante quanto a métrica final.

01



AVALIAÇÃO

0% de sobreposição
entre conjuntos

- ✓ Agrupamento por perfil
- ✓ StratifiedGroupKFold
- ✓ Teste mais confiável

02



MODELO

KNN • F1 2,94%
critério definido

- ✓ Maior F1 para TARGET = 1
- ✓ Comparado com 3 algoritmos
- ✓ Métricas avaliadas na classe minoritária

03



LEITURA

Sinal preditivo
limitado

- ✓ AUCs próximas de 0,50
- ✓ Capacidade discriminativa limitada
- ✓ Não recomendado como critério único de decisão

Obrigado.



USO RECOMENDADO

Ferramenta de apoio à análise de crédito — não um critério único de decisão.